

Análise Exploratória da Qualidade do Ar (EPA) - New York (2025)

Introdução

Este notebook apresenta uma análise exploratória dos dados de qualidade do ar da cidade de **New York**, no ano de **2025**, utilizando dados públicos da **EPA (Environmental Protection Agency)**.

A base utilizada é a **Daily Summary Data**, disponível em:

https://aqs.epa.gov/aqsweb/airdata/download_files.html

Nesta análise, a sigla **AQI** significa **Air Quality Index (Índice de Qualidade do Ar)**.

Objetivos desta análise:

- Carregar e preparar os dados
- Explorar estatísticas descritivas do AQI (Índice de Qualidade do Ar)
- Comparar comportamento do índice ao longo do tempo
- Visualizar tendências ao longo do tempo

```
In [ ]: # Importação das bibliotecas principais
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

sns.set(style='whitegrid')
plt.rcParams['figure.figsize'] = (12, 6)
```

Carregamento dos dados

Nesta etapa, vamos ler o arquivo CSV diretamente de dentro do arquivo ZIP.

```
In [ ]: # Caminho do arquivo ZIP
caminho_zip = r'C:\\Users\\Guilherme_Zanini\\Desktop\\Pos-unisinos\\Introducao_a

# Leitura do CSV dentro do ZIP
df = pd.read_csv(caminho_zip, compression='zip')

# Padronização dos nomes das colunas para facilitar a análise
df.columns = (
    df.columns
    .str.strip()
    .str.lower()
    .str.replace(' ', '_', regex=False)
)

df.head()
```

```
C:\Users\Guilherme_Zanini\AppData\Local\Temp\ipykernel_38616\2416796137.py:5: DtypeWarning: Columns (0: Event Type) have mixed types. Specify dtype option on import or set low_memory=False.
```

```
df = pd.read_csv(caminho_zip, compression='zip')
```

Out[]:

	state_code	county_code	site_num	parameter_code	poc	latitude	longitude	dat
--	------------	-------------	----------	----------------	-----	----------	-----------	-----

0	1	3	10	44201	1	30.497478	-87.880258	NA
---	---	---	----	-------	---	-----------	------------	----

1	1	3	10	44201	1	30.497478	-87.880258	NA
---	---	---	----	-------	---	-----------	------------	----

2	1	3	10	44201	1	30.497478	-87.880258	NA
---	---	---	----	-------	---	-----------	------------	----

3	1	3	10	44201	1	30.497478	-87.880258	NA
---	---	---	----	-------	---	-----------	------------	----

4	1	3	10	44201	1	30.497478	-87.880258	NA
---	---	---	----	-------	---	-----------	------------	----

5 rows × 29 columns



In []: `df.info()`

```
<class 'pandas.DataFrame'>
RangeIndex: 249474 entries, 0 to 249473
Data columns (total 29 columns):
#   Column                Non-Null Count  Dtype
---  -
0   state_code            249474 non-null  int64
1   county_code           249474 non-null  int64
2   site_num              249474 non-null  int64
3   parameter_code        249474 non-null  int64
4   poc                   249474 non-null  int64
5   latitude              249474 non-null  float64
6   longitude              249474 non-null  float64
7   datum                 249474 non-null  str
8   parameter_name        249474 non-null  str
9   sample_duration       249474 non-null  str
10  pollutant_standard    249474 non-null  str
11  date_local            249474 non-null  str
12  units_of_measure      249474 non-null  str
13  event_type            2572 non-null    str
14  observation_count      249474 non-null  int64
15  observation_percent    249474 non-null  float64
16  arithmetic_mean        249474 non-null  float64
17  1st_max_value          249474 non-null  float64
18  1st_max_hour           249474 non-null  int64
19  aqi                    249473 non-null  float64
20  method_code           249474 non-null  int64
21  method_name           249474 non-null  str
22  local_site_name        244330 non-null  str
23  address                249474 non-null  str
24  state_name             249474 non-null  str
25  county_name            249474 non-null  str
26  city_name              249474 non-null  str
27  cbsa_name              225051 non-null  str
28  date_of_last_change    249474 non-null  str
dtypes: float64(6), int64(8), str(15)
memory usage: 55.2 MB
```

```
In [ ]: df.shape
```

```
Out[ ]: (249474, 29)
```

Tratamento dos dados

Passos:

- Converter `date_local` para datetime
- Verificar e tratar valores nulos
- Filtrar apenas New York
- Selecionar colunas relevantes para a análise

```
In [ ]: df['date_local'] = pd.to_datetime(df['date_local'], errors='coerce')
colunas_principais = ['date_local', 'state_name', 'city_name', 'parameter_name',
df[colunas_principais].isnull().sum()
```

```
Out[ ]: date_local      0
state_name      0
city_name       0
parameter_name  0
aqi             1
arithmetic_mean 0
dtype: int64
```

```
In [ ]: df_limpo = df.dropna(subset=['date_local', 'city_name', 'parameter_name', 'aqi'])
df_ny = df_limpo[df_limpo['city_name'].str.upper() == 'NEW YORK'].copy()
colunas_relevantes = ['date_local', 'state_name', 'county_name', 'city_name', 'parameter_name', 'aqi']
df_ny = df_ny[colunas_relevantes]
print('Dimensão após limpeza e filtro:', df_ny.shape)
df_ny.head()
```

Dimensão após limpeza e filtro: (1130, 10)

```
Out[ ]:      date_local  state_name  county_name  city_name  parameter_name  sample_duration
156368  2025-03-31    New York      Bronx      New York      Ozone          8-HR RUN BEGIN F
156369  2025-04-01    New York      Bronx      New York      Ozone          8-HR RUN BEGIN F
156370  2025-04-02    New York      Bronx      New York      Ozone          8-HR RUN BEGIN F
156371  2025-04-03    New York      Bronx      New York      Ozone          8-HR RUN BEGIN F
156372  2025-04-04    New York      Bronx      New York      Ozone          8-HR RUN BEGIN F
```

Exploração e estatística descritiva

```
In [ ]: df_ny['aqi'].describe()
```

```
Out[ ]: count      1130.000000
mean         40.981416
std          18.026961
min           6.000000
25%          31.000000
50%          37.000000
75%          44.000000
max          154.000000
Name: aqi, dtype: float64
```

```
In [ ]: media_aqi = df_ny['aqi'].mean()
mediana_aqi = df_ny['aqi'].median()
desvio_padrao_aqi = df_ny['aqi'].std()
min_aqi = df_ny['aqi'].min()
max_aqi = df_ny['aqi'].max()
quartis_aqi = df_ny['aqi'].quantile([0.25, 0.50, 0.75])
print(f'Média AQI: {media_aqi:.2f}')
print(f'Mediana AQI: {mediana_aqi:.2f}')
print(f'Desvio padrão AQI: {desvio_padrao_aqi:.2f}')
print(f'Mínimo AQI: {min_aqi:.2f}')
```

```
print(f'Máximo AQI: {max_aqi}')
print('Quartis AQI:')
print(quartis_aqi)
```

```
Média AQI: 40.98
Mediana AQI: 37.00
Desvio padrão AQI: 18.03
Mínimo AQI: 6.0
Máximo AQI: 154.0
Quartis AQI:
0.25    31.0
0.50    37.0
0.75    44.0
Name: aqi, dtype: float64
```

```
In [ ]: df_ny['parameter_name'].value_counts()
```


```
Out[ ]: parameter_name
Ozone    1130
Name: count, dtype: int64
```

```
In [ ]: aqi_medio_poluente = df_ny.groupby('parameter_name')['aqi'].mean().sort_values(aqi_medio_poluente)
```

```
Out[ ]: parameter_name
Ozone    40.981416
Name: aqi, dtype: float64
```

Visualizações

```
In [ ]: aqi_tempo = df_ny.groupby('date_local')['aqi'].mean().reset_index()
plt.figure()
sns.lineplot(data=aqi_tempo, x='date_local', y='aqi', color='tab:blue')
plt.title('AQI médio ao longo do tempo - New York (2025)')
plt.xlabel('Data')
plt.ylabel('AQI médio')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```




```
In [ ]: # Gráfico 2: Barras - AQI médio por mês
df_ny['mes'] = df_ny['date_local'].dt.to_period('M').astype(str)
aqi_medio_mes = df_ny.groupby('mes')['aqi'].mean().reset_index()

plt.figure()
sns.barplot(data=aqi_medio_mes, x='mes', y='aqi', color='tab:orange')
plt.title('AQI médio por mês - New York (2025)')
plt.xlabel('Mês')
plt.ylabel('AQI médio')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```



```
In [ ]: plt.figure()
sns.histplot(df_ny['aqi'], bins=30, kde=True, color='tab:green')
plt.title('Distribuição do AQI - New York (2025)')
plt.xlabel('AQI')
plt.ylabel('Frequência')
plt.tight_layout()
plt.show()
```



Interpretação dos gráficos

- **AQI (Índice de Qualidade do Ar) ao longo do tempo:** observamos aumento do índice do início do ano até o verão, com os maiores picos em 30/07/2025 (125,4), 23/06/2025 (120,0) e 12/06/2025 (115,4).
- **AQI médio por mês:** os maiores valores médios aparecem em junho e julho, piora sazonal da qualidade do ar no meio do ano.
- **Distribuição do AQI:** a distribuição concentra-se em valores moderados (mediana 37, Q1 31, Q3 44), mas com cauda à direita, indicando poucos dias com índice muito alto (máximo 154).

Leitura geral: a qualidade do ar em New York em 2025 foi, na maior parte do tempo moderada para ozônio, com episódios pontuais de piora mais forte no período de verão.

Conclusão

A análise exploratória com dados da EPA para New York (2025) mostrou um AQI (Índice de Qualidade do Ar) médio de 40,98, mediana 37, desvio padrão 18,03, mínimo 6 e máximo 154 para o poluente analisado.

Principais achados:

- Houve aumento do índice ao longo dos meses, com valores mais altos no meio do ano (especialmente junho e julho).
- Existem dias extremos de pior qualidade do ar, embora a maior parte dos dias esteja em uma faixa intermediária do índice.
- O arquivo utilizado (`daily_44201_2025`) representa medições de ozônio, portanto a análise por poluente ficou concentrada nesse parâmetro.
- O AQI é um indicador resumido da qualidade do ar e pode ser complementado por variáveis meteorológicas e por comparação com outros anos.