Tecnologias de Armazenamento de Dados para Ciência de Dados

Entrega 2 – Desenho de Arquitetura de Dados

Guilherme Zanini da Silva

Universidade do Vale do Rio dos Sinos (Unisinos)
Av. Unisinos, 950 - Cristo Rei – 93022-750 – São Leopoldo – RS – Brazil
{guilhermezsilva@hotmail.com}

1. Objetivo

O objetivo desta entrega é definir uma arquitetura lógica de dados para o projeto InsightFuel, considerando as fontes de dados identificadas na etapa anterior e os requisitos necessários para ingestão, armazenamento, processamento, integração e disponibilização das informações.

A arquitetura proposta utiliza uma arquitetura medallion, separando os dados brutos dos dados tratados e dos dados preparados para consumo analítico. Para isso, serão utilizadas as camadas Bronze, Silver e Gold.

A solução proposta utiliza Python para apoio aos processos de ingestão e tratamento, Google Cloud Storage (GCS) para armazenamento dos arquivos brutos, BigQuery para armazenamento e processamento dos dados estruturados, Apache Airflow para orquestração do pipeline e Power BI para consumo e visualização das informações.

A arquitetura considera as quatro fontes de dados identificadas anteriormente: Série Histórica de Preços de Combustíveis e de GLP da ANP, Estimativas da População do IBGE, Produto Interno Bruto dos Municípios do IBGE e Índice Nacional de Preços ao Consumidor Amplo (IPCA).

2. Arquitetura lógica de dados

A arquitetura foi estruturada para permitir que os dados provenientes das diferentes fontes sejam armazenados inicialmente em seu formato original e posteriormente passem por processos de limpeza, padronização, validação e integração.

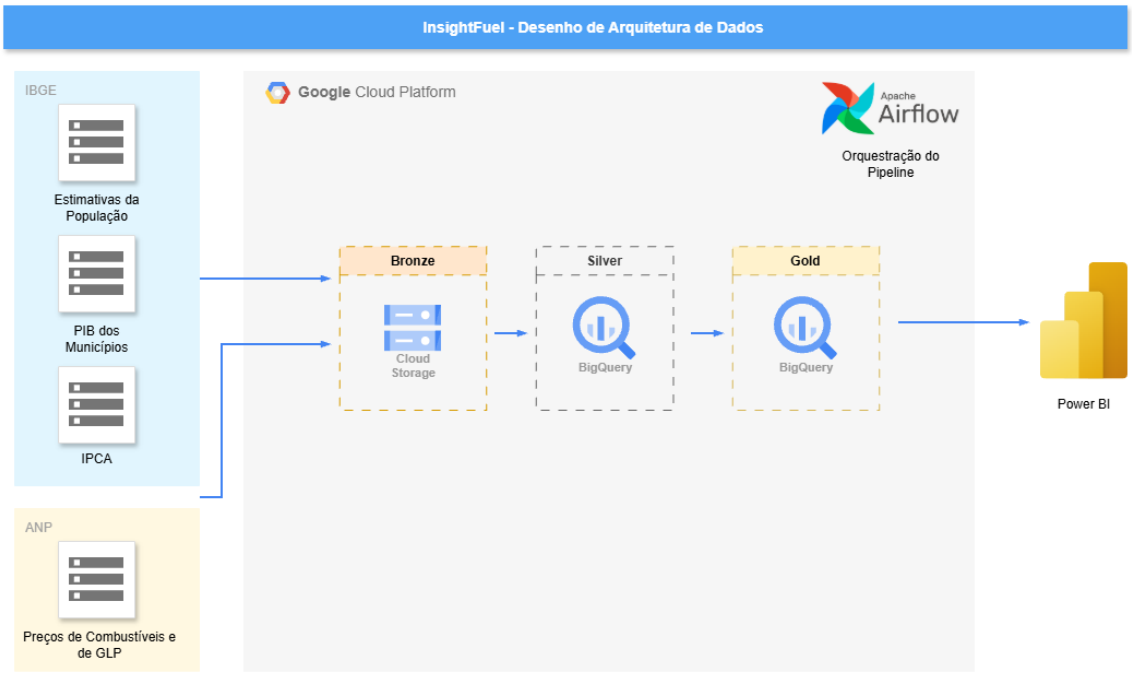
Os arquivos obtidos das fontes serão inicialmente armazenados na camada Bronze no Google Cloud Storage. Após a ingestão, os dados serão processados e disponibilizados no BigQuery, onde serão organizados nas camadas Silver e Gold.

A camada Silver será responsável pelos dados tratados e padronizados, enquanto a camada Gold conterá informações integradas e agregadas, preparadas para utilização em análises e ferramentas de visualização.

O Apache Airflow será responsável pela orquestração das diferentes etapas do pipeline, controlando dependências entre as tarefas e permitindo o acompanhamento das execuções.

O Power BI será utilizado como camada de consumo dos dados disponibilizados na Gold.

2.1. Diagrama da arquitetura



3. Camadas da arquitetura

3.1. Camada Bronze

A camada Bronze será responsável pelo armazenamento dos dados brutos provenientes das fontes externas. Os arquivos serão armazenados no Google Cloud Storage preservando, sempre que possível, sua estrutura e conteúdo originais.

Essa camada terá como objetivo manter uma cópia dos dados recebidos das fontes, permitindo rastreabilidade e possibilitando que os dados sejam reprocessados posteriormente sem necessidade de uma nova obtenção na fonte original.

Os arquivos poderão ser organizados no armazenamento de acordo com sua origem e período de referência.

Exemplo de organização:

bronze/

```
│
├── anp/
│   ├── 2024/
│   ├── 2025/
│   └── 2026/
│
```

└── ibge/
    ├── populacao/
    ├── pib_municipios/
    └── ipca/

Também serão mantidas informações de controle da ingestão, como nome do arquivo, fonte, data de processamento e período de referência, permitindo identificar quais dados já foram processados.

3.2. Camada Silver

A camada Silver será armazenada no BigQuery e será responsável pela disponibilização dos dados tratados, estruturados e padronizados.

Nessa etapa serão realizadas operações de limpeza, conversão de tipos, tratamento de valores inválidos, padronização de nomes de campos, tratamento de registros duplicados e validações de qualidade.

Para os dados municipais, será realizada a padronização da identificação dos municípios, utilizando o código do município do IBGE sempre que disponível.

Os dados provenientes da ANP serão tratados mantendo informações como produto, estabelecimento, município, UF, data da coleta e preço de venda.

Os dados de população e PIB serão estruturados por município, enquanto o IPCA será estruturado por período de referência.

Como resultado, a Silver deverá possuir conjuntos de dados independentes e padronizados para cada uma das fontes utilizadas.

Exemplo lógico:

- silver_precos_anp
- silver_populacao_ibge
- silver_pib_municipios_ibge
- silver_ipca_ibge

3.3. Camada Gold

A camada Gold será armazenada no BigQuery e será responsável pela disponibilização dos dados preparados para consumo analítico.

Nessa camada serão realizadas integrações e agregações dos dados provenientes da Silver.

Os dados de preços da ANP poderão ser agregados mensalmente por município, produto e UF, permitindo calcular indicadores como preço médio, preço mínimo, preço máximo e quantidade de observações.

As informações municipais provenientes do IBGE poderão ser associadas aos dados de preços por meio da identificação do município. A população permitirá caracterizar o porte populacional dos municípios, enquanto o PIB e o PIB per capita permitirão acrescentar informações sobre suas características econômicas.

Como os dados disponíveis do PIB dos Municípios possuem informações até 2023, os indicadores desse período poderão ser utilizados como referência econômica municipal para análises envolvendo períodos posteriores.

O IPCA poderá ser associado aos dados por meio do mês e ano de referência, permitindo posteriormente a realização de análises considerando a evolução da inflação.

A Gold fornecerá, portanto, conjuntos de dados preparados para análises e consumo por ferramentas como o Power BI.

Exemplo de saída analítica:

gold_precos_combustiveis_mensal
ano
mes
uf
cd_municipio
nm_municipio
produto
vl_preco_medio
vl_preco_minimo
vl_preco_maximo
qtd_observacoes
qtd_populacao
pib
pib_per_capita
ipca

4. Especificação lógica do pipeline

O pipeline será responsável por conduzir os dados desde sua obtenção nas fontes até a disponibilização para consumo analítico.

O processo inicia pela obtenção dos arquivos provenientes da ANP e do IBGE. Os arquivos são validados e armazenados na camada Bronze no Google Cloud Storage.

Após a ingestão, os arquivos são processados e transformados para geração das tabelas Silver no BigQuery. Nessa etapa são executados os processos de limpeza, padronização, tipagem, deduplicação e validação de qualidade.

Após a conclusão dos tratamentos, os dados da Silver são utilizados para geração da camada Gold. Essa etapa realizará as agregações e integrações necessárias para disponibilizar uma visão analítica dos preços de combustíveis.

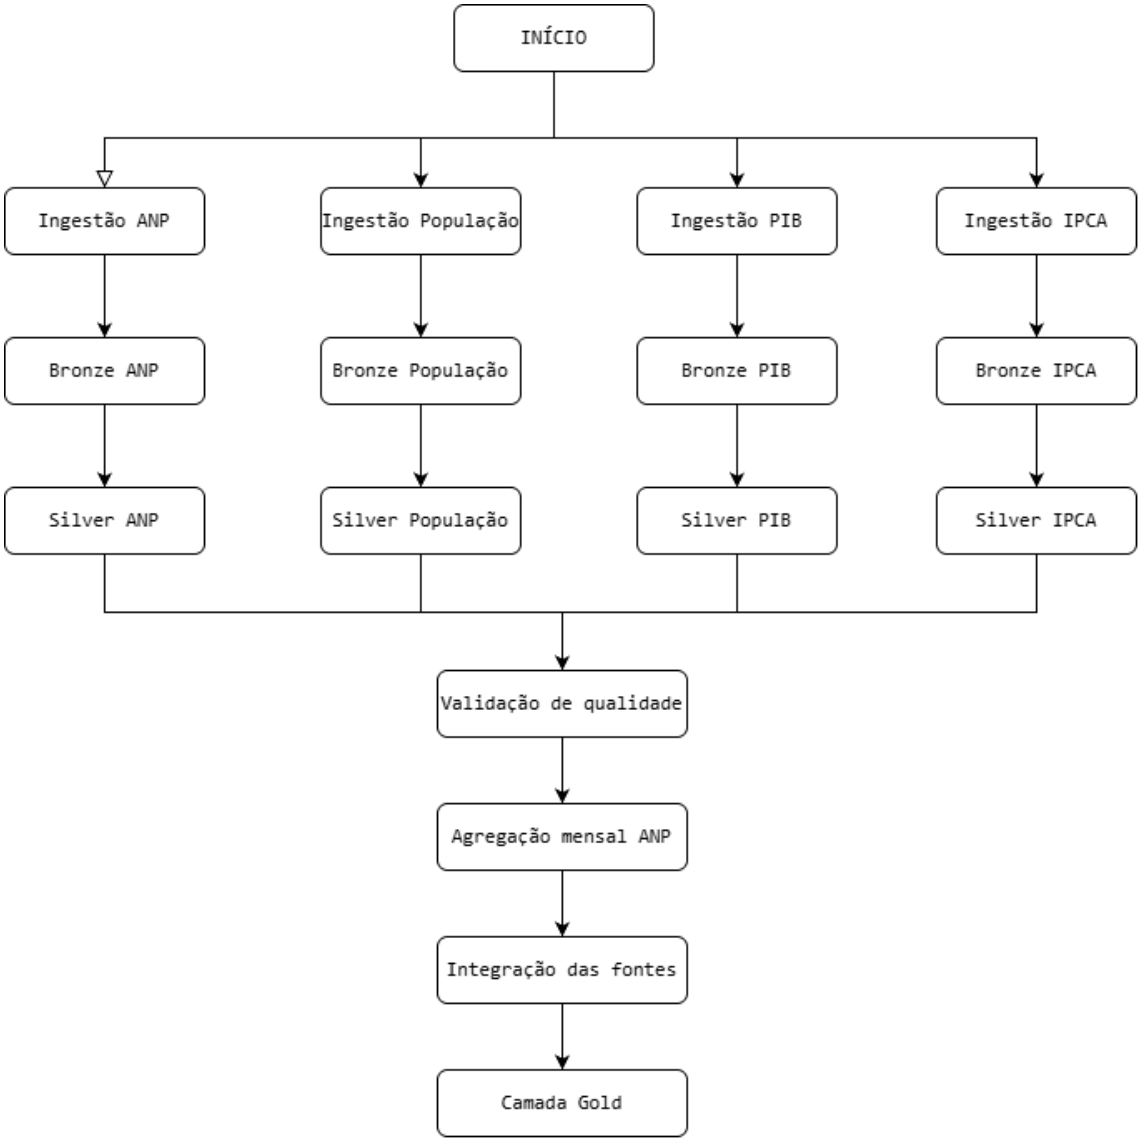
O Apache Airflow será responsável por controlar a sequência e as dependências entre essas etapas, garantindo que uma etapa dependente seja executada somente após a conclusão das tarefas necessárias.

5. Tabela de tarefas

N	Tarefa	Input	Output	Testes	SLA	Observações

1	Ingestão ANP	Arquivos ANP	Arquivos ANP na Bronze/GCS	Existência do arquivo, formato e arquivo não vazio	Conforme atualização da fonte	Preservar arquivo original
2	Ingestão População	Arquivo IBGE População	Arquivo na Bronze/GCS	Existência, formato e arquivo não vazio	Conforme atualização da fonte	Preservar arquivo original
3	Ingestão PIB	Arquivo IBGE PIB Municípios	Arquivo na Bronze/GCS	Existência, formato e arquivo não vazio	Conforme atualização da fonte	PIB disponível até 2023
4	Ingestão IPCA	Arquivo IBGE IPCA	Arquivo na Bronze/GCS	Existência, formato e arquivo não vazio	Conforme atualização da fonte	Fonte com atualização periódica
5	Processamento ANP	Bronze ANP	Silver ANP	Tipos, campos obrigatórios, preços inválidos e duplicidade	Após ingestão	Padronização dos dados de preços
6	Processamento População	Bronze População	Silver População	Código do município, população e duplicidade	Após ingestão	Padronização municipal
7	Processamento PIB	Bronze PIB	Silver PIB	Código do município, ano, PIB e duplicidade	Após ingestão	Utilização do último período disponível quando necessário
8	Processamento IPCA	Bronze IPCA	Silver IPCA	Período, valores nulos e duplicidade	Após ingestão	Padronização de ano e mês
9	Validação Silver	Tabelas Silver	Dados validados	Quantidade de registros, nulos, duplicados e chaves	Após processamento	Falhas críticas impedem geração da Gold
10	Agregação de preços	Silver ANP	Preços mensais agregados	Valores mínimos/máximos, quantidade e consistência das agregações	Após validação	Agregação por município, produto e período
11	Integração das fontes	Tabelas Silver + preços agregados	Gold	Integridade dos relacionamentos e registros sem correspondência	Após agregação	Integração municipal e temporal
12	Disponibilização	Gold	Dados disponíveis para consumo	Existência e atualização dos dados	Após processamento Gold	Fonte para análises e Power BI

6. Fluxograma DAG - insightfuel_pipeline



7. Estratégia para evitar duplicação

Para garantir que o reprocessamento do pipeline não gere registros duplicados, será utilizada uma estratégia de processamento idempotente, permitindo que uma mesma entrada possa ser processada novamente sem produzir registros adicionais indevidos.

Na camada Bronze, os arquivos serão identificados por informações como fonte, nome do arquivo e período de referência. Antes de uma nova ingestão, será verificado se o arquivo já foi registrado como processado.

Na camada Silver, serão definidas chaves de negócio de acordo com a granularidade de cada fonte. Os registros serão validados para identificação de possíveis duplicidades antes da disponibilização dos dados tratados.

Para os dados da ANP, será considerada como chave de negócio a combinação do CNPJ da revenda, produto e data da coleta. Durante o processamento para a camada Silver, serão identificados e removidos registros integralmente duplicados. A validação realizada

sobre o arquivo analisado identificou ocorrências de registros repetidos, reforçando a necessidade da etapa de deduplicação antes da disponibilização dos dados tratados.

Para as fontes municipais do IBGE, a identificação dos registros considerará o código do município e o período de referência. Para o IPCA, será utilizado o período de referência do indicador.

Nas cargas realizadas no BigQuery, o processamento deverá priorizar operações que permitam atualizar registros existentes ou inserir somente registros ainda não processados, evitando a simples inclusão repetida dos mesmos dados.

Essa estratégia possibilitará executar novamente uma tarefa ou período em caso de falha sem provocar duplicação das informações nas camadas Silver e Gold.

8. Disponibilização dos dados

Após o processamento e integração das fontes, os dados da camada Gold serão disponibilizados para consumo analítico.

O BigQuery será utilizado como repositório da camada analítica e poderá ser conectado ao Power BI para construção de relatórios e visualizações.

A estrutura proposta permitirá analisar a evolução dos preços dos combustíveis por período, produto e município e relacionar essas informações a características populacionais e econômicas dos municípios, além de permitir análises considerando a evolução da inflação.

A separação entre Bronze, Silver e Gold também permitirá que novas fontes sejam incorporadas futuramente sem necessidade de modificar completamente a arquitetura existente.